



# Estimación en dominios de indicadores socioeconómicos a partir de la Encuesta Continua de Hogares

Estudiante:

- Mauricio Pittamiglio

Tutores:

- Ignacio Álvarez-Castro
- Juan José Goyeneche

# Introducción

- Indicadores
- Encuesta Continua de Hogares (ECH)
- Métodos estadísticos
- Métodos computacionales
- Discusión


# Indicadores

Los indicadores presentados en este trabajo son calculados todos los años por el Observatorio Territorio Uruguay (OTU) perteneciente a la Oficina de Planeamiento y Presupuesto (OPP).

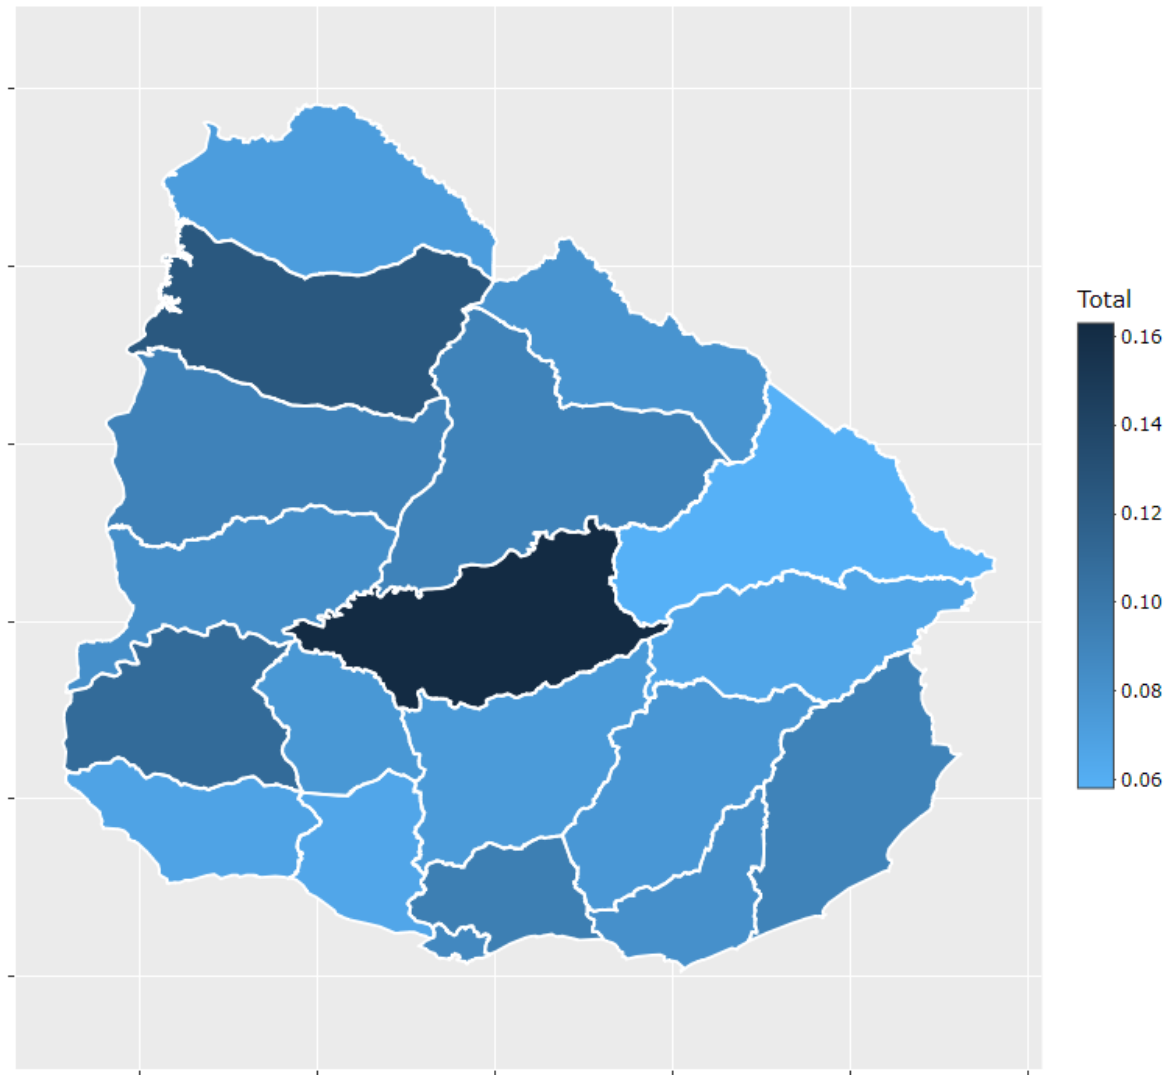
Categorías: educación, salud, mercado laboral, ingresos y bienestar, tecnología y comunicación, demografía, viviendas y hogares.

En total son 53 indicadores socio-económicos, todos desagregados por departamento y a su vez, algunos de estos se desagregan también por sexo o tramos etarios.


# Ejemplo Tasa de desempleo



# Ejemplo Tasa de desempleo



# Ejemplo Tasa de desempleo



# ECH

- Realizada por el INE desde 1968.
- Brinda indicadores oficiales del mercado laboral y de ingresos.

## Diseño muestral

- Estratificado
- Por conglomerados
- Varias etapas de selección



# Diseño muestral

- Se divide la población  $U$  en  $H$  estratos y se selecciona una muestra  $s_h$  en c/u.
- Dentro de cada estrato se encuentran  $M_h$  UPM de las cuales se seleccionan  $m_h$  con probabilidad proporcional al tamaño, en base a una medida de tamaño (MOS).
- $N_j$  cantidad de viviendas de la UPM según censo del 2011.
- Se seleccionan  $n_{jh}$  unidades dentro de cada UPM seleccionada previamente, bajo un MAS.
- El número de unidades seleccionadas en cada UPM es fijo, es decir  $n_j = \alpha$ .

# Métodos estadísticos

- Notación y definiciones
- Estimación puntual e IC
- Errores estándar (SE)

# Notación y definiciones

Dada la población objetivo  $U$  de tamaño  $N$ , se selecciona una muestra  $s$  de tamaño  $n$ .

Parámetros de interés:

# Notación y definiciones

Dada la población objetivo  $U$  de tamaño  $N$ , se selecciona una muestra  $s$  de tamaño  $n$ .

Parámetros de interés:

- $t = \sum_{i \in U} y_i$

# Notación y definiciones

Dada la población objetivo  $U$  de tamaño  $N$ , se selecciona una muestra  $s$  de tamaño  $n$ .

Parámetros de interés:

- $t = \sum_{i \in U} y_i$

- $R = \frac{\sum_{i \in U} y_i}{\sum_{i \in U} z_i}$

# Dominios

- Subpoblaciones, para las cuales se computan de manera específica, tanto estimaciones puntuales como intervalos de confianza, son denominadas dominios (Sarndal et al., 2003).
- Pueden clasificarse en planeados y no planeados

# Estimaciones puntuales

Estimador de Horvitz-Thompson para t:

$$\cdot \hat{t}_{\pi} = \sum_s w_i \times y_i$$

Donde  $w_i$  es el peso de la unidad  $i$  incluida en la muestra. Más precisamente el ponderador o peso muestral  $w_i$  se define como el inverso de la probabilidad de inclusión  $\pi_i$ .

# Probabilidad de inclusión

La probabilidad de inclusión en la muestra de una unidad  $i$  queda definida como:

$$\pi_{ijh} = \pi_{jh} \times \pi_{i|jh}$$



# Probabilidad de inclusión

La probabilidad de inclusión en la muestra de una unidad  $i$  queda definida como:

$$\pi_{ijh} = \pi_{jh} \times \pi_{i|jh}$$

Donde  $\pi_{jh}$  es la probabilidad de selección de la UPM  $j$  en el estrato  $h$  definida como:

$$\pi_{jh} = m_h \times \frac{MOS_j}{\sum_{j=1}^{M_h} MOS_j}$$

# Probabilidad de inclusión

La probabilidad de inclusión en la muestra de una unidad  $i$  queda definida como:

$$\pi_{ijh} = \pi_{jh} \times \pi_{i|jh}$$

Donde  $\pi_{jh}$  es la probabilidad de selección de la UPM  $j$  en el estrato  $h$  definida como:

$$\pi_{jh} = m_h \times \frac{MOS_j}{\sum_{j=1}^{M_h} MOS_j}$$

Mientras que  $\pi_{i|jh}$  es la probabilidad de selección de la unidad  $i$  dentro de la UPM  $j$ :

$$\pi_{i|jh} = \frac{n_{jh}}{MOS_j}$$

# Estimaciones puntuales

Los indicadores trabajados son en su mayoría ratios, por lo que el estimador queda definido de la siguiente manera:

$$\widehat{R} = \frac{\sum_{i \in s} y_i \times w_i}{\sum_{i \in s} z_i \times w_i}$$

# Estimaciones puntuales

Los indicadores trabajados son en su mayoría ratios, por lo que el estimador queda definido de la siguiente manera:

$$\widehat{R} = \frac{\sum_{i \in s} y_i \times w_i}{\sum_{i \in s} z_i \times w_i}$$

- Los ponderadores son ajustados por la no respuesta.

# Intervalos de confianza

- Son una medida de calidad de las estimaciones.

# Intervalos de confianza

- Son una medida de calidad de las estimaciones.

$$\hat{\theta} \pm z_{1-\frac{\alpha}{2}} \times \widehat{SE}(\hat{\theta})$$

# Intervalos de confianza

- Son una medida de calidad de las estimaciones.

$$\hat{\theta} \pm z_{1-\frac{\alpha}{2}} \times \widehat{SE}(\hat{\theta})$$

- Se trabaja con una confianza del 95%, por lo que se sustituye  $z_{1-\alpha/2}$  por 1.96.

# Errores estándar (SE)

- El SE es una medida de la precisión de la estimación.
- Se busca que la estimación de los SE capte de la mejor manera posible la variabilidad de las estimaciones.



# Errores estándar (SE)

- El SE es una medida de la precisión de la estimación.
- Se busca que la estimación de los SE capte de la mejor manera posible la variabilidad de las estimaciones.
- Previo a 2018 no se contaba con información clave sobre el diseño muestral.

# Errores estándar (SE)

- El SE es una medida de la precisión de la estimación.
- Se busca que la estimación de los SE capte de la mejor manera posible la variabilidad de las estimaciones.
- Previo a 2018 no se contaba con información clave sobre el diseño muestral.
- No existen métodos exactos para un diseño complejo como el de la ECH.

# Errores estándar (SE)

- El SE es una medida de la precisión de la estimación.
- Se busca que la estimación de los SE capte de la mejor manera posible la variabilidad de las estimaciones.
- Previo a 2018 no se contaba con información clave sobre el diseño muestral.
- No existen métodos exactos para un diseño complejo como el de la ECH.
- Aproximación de una etapa (Lumley, 2010) en conjunto con la linearización de Taylor.

# Aproximación de una etapa

- Utiliza únicamente la varianza de los estimadores en la primera etapa.
- Por lo tanto, a la hora de estimar la varianza del estimador del total de una variable  $y$ , se utiliza la siguiente fórmula:

$$\widehat{\text{SE}}^2(\hat{t}) = \hat{V}(\hat{t}) = \sum_{h=1}^H \frac{1}{m_h(m_h-1)} \times \sum_{j \in s_h} (\hat{t}_{jh} \times m_h - \hat{t}_h)^2$$

# Aproximación de una etapa

- Utiliza únicamente la varianza de los estimadores en la primera etapa.
- Por lo tanto, a la hora de estimar la varianza del estimador del total de una variable  $y$ , se utiliza la siguiente fórmula:

$$\widehat{SE}^2(\hat{t}) = \hat{V}(\hat{t}) = \sum_{h=1}^H \frac{1}{m_h(m_h-1)} \times \sum_{j \in s_h} (\hat{t}_{jh} \times m_h - \hat{t}_h)^2$$

- Siendo  $\hat{t}_{jh} = \sum_{i \in s_{jh}} w_i \times y_i$  la estimación del total de la variable  $y$  en la UPM  $j$  perteneciente al estrato  $h$
- $\hat{t}_h = \sum_{j \in s_h} \hat{t}_{jh}$  la estimación del total de la variable  $y$  en el estrato  $h$ .

# Estimación en dominios

En el caso de la estimación en dominios se debe reemplazar la variable  $y$ , por una variable  $y_d$  que toma el valor  $y$  cuando la unidad pertenece al dominio  $d$  en cuestión, y cero cuando no pertenece al dominio.

# Linearización de Taylor

- La aproximación por linearización de Taylor, planteada entre otros por (Sarndal et al., 2003), se basa en expresar el estimador no lineal como función de estimadores lineales.

# Linearización de Taylor

- La aproximación por linearización de Taylor, planteada entre otros por (Sarndal et al., 2003), se basa en expresar el estimador no lineal como función de estimadores lineales.
- Se utiliza el desarrollo de Taylor de primer orden para aproximar el estimador de ratio:

$$\hat{R} \approx R + \frac{1}{t_z} \times \sum_{i \in s} w_i \times (y_i - Rz_i)$$



# Linearización de Taylor

Posteriormente se aproxima la varianza de la estimación mediante la varianza de primer orden utilizando el método planteado anteriormente

$$\widehat{\text{SE}}^2(\hat{R}) = \frac{1}{\hat{t}_z^2} \times \sum_{h=1}^H \frac{1}{m_h(m_h-1)} \times \sum_{j \in s_h} (\hat{t}_{r,jh} \times m_h - \hat{t}_{r,h})^2$$

# Linearización de Taylor

Posteriormente se aproxima la varianza de la estimación mediante la varianza de primer orden utilizando el método planteado anteriormente

$$\widehat{\text{SE}}^2(\hat{R}) = \frac{1}{\hat{t}_z^2} \times \sum_{h=1}^H \frac{1}{m_h(m_h-1)} \times \sum_{j \in s_h} (\hat{t}_{r,jh} \times m_h - \hat{t}_{r,h})^2$$

- Siendo  $\hat{t}_z = \sum_{i \in s} w_i \times z_i$  la estimación del total de la variable  $z$ .
- $\hat{t}_{r,jh} = \sum_{i \in s_{jh}} w_i \times r_i$  la estimación del total de la variable  $r$  en la UPM  $j$  perteneciente al estrato  $h$
- $\hat{t}_{r,h} = \sum_{j \in s_h} \hat{t}_{r,jh}$  la estimación del total de la variable  $r$  en el estrato  $h$ .

# Métodos computacionales

- Se utiliza la librería *srvyr* en *R*.
- Cuenta con funciones como *survey\_mean*, *survey\_ratio* y *survey\_total*.

# Estimación de los indicadores

Se presenta un breve ejemplo de cómo se utilizan las funciones de esta librería, para el caso concreto del indicador *Utilización de computadora el último mes por sexo*.

```
pr<-echP%>% as_survey_design(ids=upm_fic, weight=pesoano
                             , strata=estrato)

diseno<- pr
filtro<- "e27>5"
variable<- "e61==1"
ind<-diseno%>%
  filter(eval(parse(text=filtro)))%>%
  group_by(dpto, e26)%>%
  summarise(estimacion.tot= survey_mean(eval(parse(text=variable))))
```

# Estimación de los indicadores

Se crearon 9 funciones, las cuales necesitan de los siguientes insumos:

# Estimación de los indicadores

Se crearon 9 funciones, las cuales necesitan de los siguientes insumos:

- El diseño muestral
- El filtro a aplicar (de ser necesario)
- Variable(s) de interés
- Vector con categorías de la variable de interés (en caso de ser necesario)

# Estimación de los indicadores

Se crearon 9 funciones, las cuales necesitan de los siguientes insumos:

- El diseño muestral
- El filtro a aplicar (de ser necesario)
- Variable(s) de interés
- Vector con categorías de la variable de interés (en caso de ser necesario)

```
funcion1(pr, "e27>5", "e61==1")
```

# Aplicación web (Shiny)

- Shiny es una librería que permite crear fácilmente aplicaciones web interactivas a partir de R.
- Contiene al menos dos componentes: UI y server.
- Programación reactiva.
- App disponible en: [GitHub](#)